



Contexte

Code

Analyse

Projet Data

Hajar BELGROUN, Mailis BRIENS,
Audrey NOURRY, Nino TISSOT



Contexte


Code

Analyse


Contexte et Problématique

Les startups pharmaceutiques

Répartition des statuts



Top 10 pays



Gestion d'investissement dans une startup pharmaceutique
Risques impliqués (temps de développement, réglementation...)

Aspect éthique important surtout dans le contexte actuel

Forte concentration des startups aux USA

Notre projet

Comment anticiper la réussite financière d'une startup pharmaceutique, tout en s'assurant qu'elle agit de manière éthique, afin d'optimiser les décisions d'allocation de capital ?

Obj : Optimiser les décisions d'investissement en intégrant ces deux dimensions

Modèle de machine learning entraîné sur les données financières historiques

Analyse automatique de l'éthique via ESG-BERT

→ Combinés en un unique score final pour guider les décisions d'investissement

Les données

Dataset de capital-risque (54 294 startups) classées par :

- Pays, Secteur, Statut actuel, Montants levés, Nombre de tours de financement, Dates clés de son développement
- Sélection du secteur pharma et biotech (**4 207 startups**)
- Résultat final connu (Acquired – succès – ou Closed – échec)

Question de qualité de la donnée (108 startups “operating”)

→ **Dataset d’entraînement final (480 startups / 333 succès, 147 échecs)**





Date de coupure : 01/01/2012

Apprentissage sur les startups fondées avant 2012 et prédiction sur celles futures (prévoir le data leakage)

Les données

Distribution du financement :

- Levé de fonds très asymétrique
- Médiane basse avec quelques levés de fonds de milliards
- Transformation logarithmique pour mieux visualiser la structure générale de la distribution
- Startups à succès → Financements importants et réguliers



Contexte

Code

Analyse


Le code

Modèle financier

Variables clés


- funding_velocity : combien la startup lève par an
→ une startup qui lève vite est un bon signal
- round_intensity : combien de tours de financement par an
→ régularité à attirer des investisseurs
- days_to_first_funding : délai entre fondation et premier financement
→ un délai court signale une reconnaissance rapide par le marché
- des variables binaires : a-t-elle eu un seed, un round A, un round B ?

Stacking




Paramètre Stacking

$$s = 1.52 \text{ lr} + 0.60 \text{ rf} + 0.97 \text{ gb} - 0.15 \text{ svm}$$



Matrice de confusion



F1 CV 5 folds : 0.786 ± 0.030
F1 Test set : 0.805
Écart : 0.019

Contexte

Code

Analyse


Résultats

Tri Financier

Contexte

Code


Analyse



Filtrage Financier : 3 622 Startups évaluées
IPO → Entreprises exclues (108)

→ Sélection des **20 meilleures** entreprises

Répartition des prédictions



Seuil du Score Stacking → Probabilité de succès


Pipeline d'Analyse Ethique (ESG-BERT)

Données Textuelles :


ClinicalTrials, PubMed et les sites web des entreprises

Score Final :

Combinaison des 2 dimensions :
70% Finance + 30% Ethique



Top 20 Startups — Score Final
(taille = score éthique · couleur = sentiment)




Code

Analyse

Résultat Final : Top 20

- Classement Final : 70% Finance + 30% Ethique
- Taille Bulle = Score éthique
- Couleur = Sentiment détecté dans les textes

Propulsion au classement grâce au Bonus Éthique



Impact de l'Éthique sur la Stratégie d'Investissement

Conclusion :

-  Bonus éthique : Classement boosté par la transparence
-  La dimension éthique est un facteur puissant
-  Sans filtre éthique = Investissement à haut risque



Développement de 2 outils

API FastAPI

Interface de programmation qui expose nos modèles via des requêtes web.

Envoie des données d'une startup et reçoit en retour un **score en temps réel**

3 routes :
score financier seul, score complet financier + éthique,
et une **route batch** (jusqu'à 100 startups en une seule requête).

Industrialisation

Dashboard interactif en HTML/CSS/JavaScript

Interface visuelle :

remplit un formulaire avec les caractéristiques d'une startup, on clique sur 'Lancer la Prédiction' → scores s'affichent instantanément avec des jauges et des graphiques.

Large accessibilité :

Permet à un analyste non technique d'utiliser notre modèle au quotidien.



Limites Identifiées et Contraintes


- a. Taille réduite de l'échantillon
- b. Analyse éthique
- c. IPO



Contexte

Code

Analyse



Taille réduite de l'échantillon
d'entraînement

Cross-validation 5 folds : score plus fiable
qu'un simple découpage train/test.

Dataset : 2012 absence des thérapies géniques
ou l'immunothérapie → **biais possibles**



Analyse éthique

ESG-BERT : uniquement le top 20
**scraping web, des appels API et du
traitement NLP** : chronophage
→ Score nul par défaut pour les 3 602
autres startups .
→ Pondération **70/30** un choix
arbitraire du fond, un fonds plus
engagé sur l'ESG : **50/50**.

IPO



Sur le modèle : on prédit
uniquement **acquisition versus
fermeture**.

IPO : sous-représentées. Prédire
le succès d'une startup 10 ans à
l'avance reste incertain, notre F1
de 80.5% est solide
→ Place du hasard sur la
trajectoire d'une entreprise.



Contexte

Code

Analyse

Merci pour votre Attention

Data is not Code numbers, it's
Code understanding

Hajar BELGROUN, Mailis BRIENS,
Audrey NOURRY, Nino TISSOT

