



Contexte

Code

Analyse

Projet Data

Hajar BELGROUN, Mailis BRIENS,
Audrey NOURRY, Nino TISSOT



Contexte


Code

Analyse


Contexte et Problématique

Les startups pharmaceutiques

Répartition des statuts



Top 10 pays



Gestion d'investissement dans une startup pharmaceutique
Risques impliqués (temps de développement, réglementation...)

Aspect éthique important surtout dans le contexte actuel

Forte concentration des startups aux USA

Notre projet

Comment anticiper la réussite financière d'une startup pharmaceutique, tout en s'assurant qu'elle agit de manière éthique, afin d'optimiser les décisions d'allocation de capital ?

Obj : Optimiser les décisions d'investissement en intégrant ces deux dimensions

Modèle de machine learning entraîné sur les données financières historiques

Analyse automatique de l'éthique via ESG-BERT

→ Combinés en un unique score final pour guider les décisions d'investissement

Les données

Dataset de capital-risque (54 294 startups) classées par :

- Pays, Secteur, Statut actuel, Montants levés, Nombre de tours de financement, Dates clés de son développement
- Sélection du secteur pharma et biotech (**4 207 startups**)
- Résultat final connu (Acquired – succès – ou Closed – échec)

Question de qualité de la donnée (108 startups “operating”)

→ **Dataset d’entraînement final (480 startups / 333 succès, 147 échecs)**





Date de coupure : 01/01/2012

Apprentissage sur les startups fondées avant 2012 et prédiction sur celles futures (prévoir le data leakage)

Les données

Distribution du financement :

- Levé de fonds très asymétrique
- Médiane basse avec quelques levés de fonds de milliards
- Transformation logarithmique pour mieux visualiser la structure générale de la distribution
- Startups à succès → Financements importants et réguliers



Contexte

Code

Analyse

Modèle de prévisions financières

Modèle financier


Stacking

Variables clés

- `funding_velocity` : combien la startup lève par an
→ une startup qui lève vite est un bon signal
- `round_intensity` : combien de tours de financement par an
→ régularité à attirer des investisseurs
- `days_to_first_funding` : délai entre la fondation et le premier financement
→ un délai court signale une reconnaissance rapide par le marché
- Des variables binaires :
`Has_seed`, `Has_venture`, `Has_grant`, `Has_round_A`, `Has_round_B`


`class_weight='balanced'`

→ le modèle pénalise autant une erreur sur un échec que sur un succès, indépendamment de leur fréquence dans le dataset




Paramètre Stacking

$$s = 1.52 \text{ lr} + 0.60 \text{ rf} + 0.97 \text{ gb} - 0.15 \text{ svm}$$



Matrice de confusion



F1 CV 5 folds : 0.786 ± 0.030
F1 Test set : 0.805
Écart : 0.019

Contexte

Code

Analyse


Résultats

Tri Financier


Contexte

Code

Analyse



Répartition des prédictions



Filtrage Financier : 3 622 Startups évaluées
IPO → Entreprises exclues (108)

Seuil du Score Stacking → Probabilité de succès

→ Sélection des **20 meilleures** entreprises

Contexte

Code

Analyse


Pipeline d'Analyse Ethique (ESG-BERT)




Données Textuelles :

ClinicalTrials, PubMed et les sites web des entreprises

Score Final :

Combinaison des 2 dimensions :
70% Finance + 30% Ethique





Code

Analyse

Résultat Final : Top 20 Startups


- Classement Final : 70% Finance + 30% Ethique
- Taille Bulle = Score éthique
- Couleur = Sentiment détecté dans les textes

Contexte

Code

Analyse

Propulsion au classement grâce au Bonus Éthique



Impact de l'Éthique sur la Stratégie d'Investissement

Conclusion :

- Bonus éthique : Classement boosté par la transparence
- La dimension éthique est un facteur puissant
- Sans filtre éthique = Investissement à haut risque



Développement de 2 outils

API FastAPI

Interface de programmation qui expose nos modèles via des requêtes web.

Envoie les données d'une startup → reçoit un score en temps réel

3 routes :


- Score financier seul
- Score complet financier + éthique
- Route batch (jusqu'à 100 startups)

Artefacts chargés au démarrage :
stack_model.pkl · scaler_pipeline.pkl ·
feature_columns.pkl

Industrialisation

Dashboard HTML/CSS/JavaScript

Interface visuelle :



Large accessibilité :

Permet à un analyste non-technique d'utiliser notre modèle au quotidien.



Dashboard HTML/CSS/JavaScript

**Biopharma ML**
Prédiction de Succès & Analyse Éthique

Nino Tissot · Audrey Hourry
Mailis Briens · Majar Belgroun
● API connectée

API URL `http://localhost:8000`

PING

📊 DONNÉES DE LA STARTUP

🔥 FEATURES FINANCIÈRES

Âge (années)

6,5

Funding Total (USD)

45000000

Nb Rounds

3

Jours 1er Funding

180

Funding Duration

1200

Funding Velocity

6923076

Round Intensity

0,46

Country Code

1

🏆 SCORE ÉTHIQUE ESG-BERT

Adjusted Ethical Score

0,73

Sentiment Score (0=négatif · 1=positif)

0,82

Data Quality Score (nb sources / 30)

0,6

📦 MODÈLE

Financier seul

Complet (F + ESG)

Contexte

Code

Analyse

Industrialisation

Types de financement

Seed

Oui

Non

Venture

Oui

Non

Grant

Oui

Non

Round A

Oui

Non

Round B

Oui

Non

Lancer la Prédiction

📊 RÉSULTATS

🚀 PRÉDICTION

Succès Probable

62.7%
SCORE FINAL

📈 DÉCOMPOSITION DES SCORES

Score Stacking

70.8%

Composante Fin.

49.5%

Score Éthique Adj.

73.0%

Composante ESG

13.1%

Score Final

62.7%


📋 DÉTAILS

STACKING
70.8%

SENTIMENT
82%

QUALITÉ ESG
60%

Limites Identifiées et Contraintes




- a. Taille réduite de l'échantillon
- b. Analyse éthique
- c. IPO

Contexte

Code

Analyse



Taille réduite de l'échantillon
d'entraînement

Cutoff 2012 → **272** startups entraînement
(**4 030 filtrées** → statut tranché uniquement)
Cross-validation 5 folds : évaluation plus fiable
Dataset 2012 : absence thérapies géniques
et immunothérapie → biais possibles



Analyse éthique

ESG-BERT : top 20 scraping web + API
+ NLP
→ chronophage
Score nul par défaut pour **3 602**
startups
→ compensé par un score qualité
données :
 $\min(\text{nb_sources} / 30 \cdot 1)$
Pondération réelle : 70/30 ajusté
qualité

IPO



Détectées via post_ipo_equity
/ post_ipo_debt
→ sous-représentées dans le
dataset 2012
Modèle prédit : acquisition vs
fermeture
F1 de **80,5%** solide mais
trajectoire à 10 ans reste
incertaine



Contexte

Code

Analyse

Merci pour votre Attention

Data is not Code numbers, it's
Code understanding

Hajar BELGROUN, Mailis BRIENS,
Audrey NOURRY, Nino TISSOT

