

Prédiction de succès en biopharma et analyse éthique

Équipe 12 — Nino Tissot · Audrey Nourry · Mailis Briens · Hajar Belgroun

Introduction

Ce projet s'inscrit dans le cadre d'une simulation de gestion d'un fonds d'investissement spécialisé dans le secteur pharmaceutique. Investir dans une startup pharmaceutique comporte un niveau de risque particulièrement élevé : les cycles de développement sont longs, la réglementation est exigeante et la majorité des molécules candidates n'atteignent jamais la phase de commercialisation. Dans ce contexte, évaluer de manière objective la viabilité d'une startup constitue un véritable défi pour les investisseurs.

À ces incertitudes économiques s'ajoute une dimension éthique propre au secteur de la santé. Une entreprise qui conduit ses essais cliniques de manière insuffisamment rigoureuse ou qui communique de façon opaque sur ses résultats peut engendrer des risques réglementaires et réputationnels majeurs, indépendamment de ses performances financières.

Dans ce cadre, notre problématique est la suivante : **comment anticiper la réussite financière d'une startup pharmaceutique tout en évaluant son intégrité éthique afin d'orienter au mieux les décisions d'allocation de capital ?** Pour y répondre, nous proposons une approche combinant deux dimensions complémentaires. D'une part, une modélisation en *machine learning* fondée sur des données financières historiques visant à prédire la probabilité de succès d'une startup. D'autre part, une analyse automatisée de la dimension éthique à l'aide d'ESG-BERT, un modèle de langage spécialisé dans l'évaluation des critères environnementaux, sociaux et de gouvernance (ESG).

Développement

1. Données

Le jeu de données *investments_VC.csv* contient 54 294 startups tous secteurs confondus. Après filtrage à l'aide de mots-clés liés aux domaines pharmaceutique et biotechnologique, l'échantillon retenu comprend 4 207 startups, dont 225 ont été acquises, 147 ont cessé leur activité et 3 730 sont encore en activité.

L'exploration des données a révélé une anomalie importante : 108 startups étiquetées *operating* présentaient des valeurs non nulles pour les variables *post_ipo_equity* ou *post_ipo_debt*. Ces informations indiquent des introductions en bourse effectives, dont le statut n'avait jamais été mis à jour dans la base de données. Les considérer comme des cas de succès a permis d'augmenter le nombre d'exemples disponibles pour l'entraînement, passant de 372 à 480 observations, soit une augmentation de 29 % sans collecte de données supplémentaire.

Afin d'éviter tout data leakage, une date de coupure a été fixée au 1er janvier 2012. Le modèle est ainsi entraîné uniquement sur des startups dont l'issue était déjà connue avant cette date, puis appliqué aux entreprises encore en activité aujourd'hui.

2. Feature Engineering

Plutôt que d'utiliser directement les variables brutes du dataset, plusieurs indicateurs financiers ont été construits afin de refléter la logique d'analyse d'un investisseur.

Parmi ces indicateurs figurent :

- l'âge de la startup à la date de coupure,
- le délai entre la fondation et le premier financement, un délai court pouvant indiquer une reconnaissance rapide par le marché,
- la durée totale de levée de fonds, plafonnée à 2012 afin d'éviter l'utilisation d'informations futures,
- la vitesse de levée de fonds, définie comme le montant total levé rapporté à l'âge de l'entreprise,
- la régularité du financement, mesurée par le nombre de tours de financement rapporté à l'âge de la startup.

À ces variables continues s'ajoutent cinq variables binaires indiquant la présence de différents types de financement : *seed*, *venture*, *grant*, *round A* et *round B*.

Les valeurs manquantes sont traitées à l'aide de `IterativeImputer` pour les modèles de régression logistique, `Random Forest` et `SVM`, une méthode d'imputation itérative plus sophistiquée qu'une simple imputation par la médiane. Le modèle `HistGradientBoosting`, quant à lui, gère nativement les valeurs manquantes et ne nécessite donc pas d'imputation préalable.

3. Modélisation

Quatre algorithmes de classification ont été entraînés :

- Régression Logistique, utilisée comme modèle linéaire de référence,
- `Random Forest`,
- `HistGradientBoosting`,
- `Support Vector Machine (SVM)`.

Afin de gérer le déséquilibre entre succès et échecs, tous les modèles utilisent le paramètre `class_weight = "balanced"`. Sans cet ajustement, le modèle pourrait apprendre à prédire systématiquement la classe majoritaire (le succès), ce qui nuirait à sa capacité de généralisation.

Chaque modèle est évalué à l'aide d'une validation croisée à 5 plis, permettant d'obtenir des estimations de performance plus robustes sur l'ensemble du jeu de données.

Plutôt que de combiner les modèles par une simple moyenne, nous avons mis en place un `StackingClassifier`. Dans cette approche, chaque modèle de base génère des prédictions *out-of-fold*, qui sont ensuite utilisées par un méta-modèle de régression logistique chargé d'apprendre la meilleure combinaison possible.

Les coefficients appris par ce méta-modèle sont les suivants :

- LR : 1,52

- GB : 0,97
- RF : 0,60
- SVM : -0,15

Ce résultat peut sembler contre-intuitif : bien que Random Forest soit le modèle individuel le plus performant, il reçoit un coefficient plus faible que les autres modèles positifs. Cela s'explique par le fait que le méta-modèle privilégie la complémentarité des informations plutôt que la performance individuelle. La régression logistique capte certaines relations linéaires que Gradient Boosting ne détecte pas, ce qui en fait un contributeur utile. À l'inverse, Random Forest produit des erreurs relativement similaires à celles de Gradient Boosting, ce qui limite l'apport d'information supplémentaire lorsqu'ils sont combinés.

Le modèle de stacking obtient un score F1 de 80,5 % sur le jeu de test, contre 78,6 % $\pm$ 3 % en validation croisée. L'écart relativement faible entre ces deux mesures suggère que le modèle généralise correctement à des données non observées.

Par ailleurs, le recall de 96 % indique que 96 % des startups ayant effectivement réussi sont correctement identifiées. Dans une logique d'investissement, manquer une opportunité prometteuse peut être plus coûteux que d'analyser quelques faux positifs supplémentaires.

4. Analyse Éthique

Pour chacune des startups figurant dans le top 20 du classement financier, des données textuelles ont été collectées automatiquement à partir de trois sources :

- ClinicalTrials.gov, pour les informations relatives aux essais cliniques,
- PubMed, pour les publications scientifiques associées,
- les sites web des entreprises, pour leurs valeurs, leur mission et leur communication institutionnelle.

Ces textes sont ensuite analysés à l'aide de ESG-BERT, un modèle de langage spécialisé dans l'évaluation des 26 catégories de critères ESG (environnementaux, sociaux et de gouvernance).

Le score obtenu est ensuite ajusté à l'aide d'une analyse de sentiment réalisée avec DistilBERT. Cette étape permet de tenir compte du contexte : par exemple, une mention de la gouvernance dans un contexte négatif ne doit pas être valorisée de la même manière qu'une mention positive.

Enfin, un `data_quality_score`, défini comme le nombre de sources collectées rapporté à 30, est utilisé pour pondérer la fiabilité du score éthique. Ainsi, une startup disposant de peu d'informations publiques (absence de publications ou de site web) verra l'impact de son score éthique réduit, ce qui évite d'attribuer arbitrairement une note faible en raison d'un manque de données.

5. Score Final et Résultats

Le score final combine les deux dimensions analysées :

70 % score financier + 30 % score éthique ajusté par la qualité des données.

Cette pondération reflète un choix stratégique du fonds d'investissement, mais elle reste entièrement paramétrable selon les priorités de l'investisseur.

Au total, 3 622 startups encore en activité ont été évaluées, les 108 IPO identifiées précédemment étant exclues, leur résultat étant déjà connu.

Parmi les entreprises analysées, *Spark Therapeutics* apparaît en tête du classement final, présentant le meilleur équilibre entre potentiel financier et score éthique au sein du top 20.

L'analyse du classement met en évidence l'effet attendu de la composante éthique : certaines startups initialement très bien classées sur le plan financier reculent dans le classement final en raison d'un score éthique plus faible. Ce résultat souligne que performance financière et intégrité éthique ne sont pas nécessairement corrélées, et que leur combinaison peut conduire à des décisions d'investissement différentes.

6. Industrialisation

Afin de rendre la solution exploitable dans un contexte opérationnel, les modèles ont été intégrés au sein d'une API développée avec FastAPI. Celle-ci expose trois routes principales :

- une route permettant de calculer le score financier uniquement,
- une route fournissant le score complet combinant les dimensions financière et éthique,
- une route batch permettant d'évaluer jusqu'à 100 startups en une seule requête.

Un dashboard interactif a également été développé afin de permettre à un analyste non technique de tester facilement différentes startups directement depuis un navigateur.

Conclusion

Le système développé atteint un score F1 de 80,5 %, avec une robustesse confirmée par les résultats obtenus en validation croisée. L'intégration d'une dimension éthique dans l'évaluation des startups modifie de manière significative le classement final et démontre qu'une approche combinant performance financière et critères extra-financiers peut apporter une valeur ajoutée réelle dans la prise de décision d'investissement.

Au-delà des résultats obtenus, ce projet nous a également confrontés à plusieurs problématiques concrètes rarement abordées de manière approfondie dans un cadre académique : la détection d'anomalies dans les données, la gestion du data leakage, le traitement du déséquilibre des classes, ainsi que la réflexion plus large sur ce que signifie réellement « bien performer » dans un contexte métier donné. Les valeurs d'AUC relativement modestes observées sur l'ensemble des modèles (entre 0,66 et 0,71) rappellent d'ailleurs que la prédiction du succès d'une startup sur un horizon de dix ans demeure intrinsèquement incertaine. Cette incertitude souligne l'importance d'une interprétation prudente des résultats et d'une transparence quant aux limites des modèles utilisés.

Si ce travail devait être poursuivi, plusieurs pistes d'amélioration pourraient être envisagées. L'enrichissement du jeu de données avec des observations postérieures à 2012 permettrait d'augmenter la taille de l'échantillon et d'améliorer potentiellement la capacité prédictive du modèle. Par ailleurs, la parallélisation du pipeline d'analyse ESG permettrait d'étendre l'évaluation éthique à l'ensemble du portefeuille plutôt qu'aux seules vingt startups les mieux classées financièrement. Enfin, la pondération actuelle entre score financier et score éthique (70/30) pourrait faire l'objet d'une validation empirique afin de mieux refléter les préférences et les stratégies d'investissement réelles.

Dans l'ensemble, ce projet illustre la manière dont les méthodes de data science peuvent contribuer à éclairer des décisions d'investissement complexes, tout en rappelant que ces outils doivent être utilisés comme des aides à la décision, et non comme des instruments prédictifs infallibles.